

Magnus v1

Primeiro fine-tune multi-fonte: YOLO11s com 8 classes treinado em dataset curado de 3 fontes públicas. Dobra a cobertura de defeitos do v0 e produz o diagnóstico mais valioso do ciclo: o gargalo é qualidade/quantidade de rótulo por classe, não arquitetura.

1. Resumo executivo

O Magnus v1 expande o detector de defeitos de pintura de 4 para **8 classes**, triplicando os parâmetros (3M → 9,4M, YOLOv8n → YOLO11s) e dobrando o dataset (2.000 → ~4.500 imagens únicas de 3 fontes curadas). O mAP50 agregado (0,655) cai versus o v0 (0,989) — **resultado esperado e diagnóstico**: o v0 media uma tarefa fácil (4 classes balanceadas, fonte única); o v1 mede uma tarefa realista. Cinco classes estão prontas para produção (mAP50 0,73–0,95); três falham por causas identificadas e endereçáveis (escassez de dados e taxonomia incoerente).

Comparativo v0 → v1

Atributo	v0	v1
Arquitetura	YOLOv8n	YOLO11s
Parâmetros	3.011.628	9.430.888 (3,1×)
GFLOPs	8,2	21,6
Camadas (fused)	73	101
Classes	4	8 (2×)
Fontes de dataset	1	3 curadas (de 13 auditadas)
Imagens de treino	1.600	3.548 (incl. oversampling de raras)
mAP50 agregado	0,989	0,655
mAP50 das 4 classes core	0,989	0,891 (média)
Inferência (T4 GPU)	—	24,1 ms
Inferência (CPU HF Spaces)	~60 ms	~130 ms estimado
Checkpoint	hf://Guguinhaxd/baja-paint-models/best.pt → hf://Guguinhaxd/magnus-v2/best.pt	

2. Setup do treino

Atributo	Valor
Hardware	Colab T4 GPU (free tier)
Epochs	150 (melhor checkpoint ~epoch 61, platô a partir de ~60)
Batch / imgsz	16 / 640
Otimizador	AdamW (auto), lr=0,000833, cosine schedule
Augmentation	mosaic 1.0 (close em 135), mixup 0,15, copy_paste 0,3, erasing 0,4, degrees ±10°, fliplr 0,5, HSV jitter
Oversampling	classes do quartil inferior ×3 (train apenas)

Dataset splits	3.548 train (215 bg) · 572 val (51 bg) · 381 test (21 bg)
Dedup	por imagem-fonte, escopo de workspace (remove aug 3× embutido do Roboflow e overlap entre projetos)
Negativos	215+51+21 imagens 'good_paint' / sem anotação
Avaliação	test split com TTA (test-time augmentation)

3. Métricas v1 (test split, TTA)

Globais

Métrica	Valor
mAP@50	0,655
mAP@50–95	0,428
Precision (média)	0,807
Recall (média)	0,617
Velocidade	2,1 ms pré + 24,1 ms inferência + 1,2 ms pós (T4)

Por classe — o resultado que importa

Classe	mAP50	mAP50-95	P	R	Instâncias	Veredito
casca_de_laranja	0,951	0,797	0,935	0,909	79	produção
water_spotting	0,928	0,758	0,858	0,907	75	produção
escorrimento	0,849	0,649	0,883	0,829	70	produção
bolha	0,836	0,596	0,878	0,805	113	produção
sujeira	0,732	0,242	0,745	0,690	58	produção
descascamento	0,493	0,248	0,886	0,450	20	faminto de dados
risco	0,253	0,078	0,358	0,227	66	taxonomia incoerente
oxidacao	0,198	0,059	0,914	0,118	17	faminto de dados

Padrão revelador: descascamento e oxidacao têm precisão alta (0,89 e 0,91) com recall baixo (0,45 e 0,12) — o modelo *sabe reconhecer* mas não encontra tudo, assinatura clássica de escassez de amostras (20 e 17 instâncias). Já risco falha dos dois lados (P=0,36, R=0,23) — assinatura de classe visualmente incoerente.

4. Análise da matriz de confusão

A matriz de confusão (runs/detect/magnus_v2/eval/confusion_matrix.png) isola as causas com precisão cirúrgica:

Observação	Números	Diagnóstico
5 classes com diagonal limpa	bolha 92, casca 73, water_spotting 69, escorrimento 59, sujeira 46 acertos; confusão entre classes	Produção-ready. O modelo separa as classes.
risco falha nos dois sentidos	26 acertos · 40 riscos reais preditos como background · 54 backgrounds preditos como risco	Fusão scratch+Crack+Paint-Crack criou classe sem identidade visual. Arranhão fino confunde com textura de fundo.
oxidacao não encontra	3 acertos · 13 perdidos para background · quase nenhum falso positivo	Não é confusão — é fome de dados (7 imagens no test).
descascamento borderline	8 acertos · 8 perdidos	Idem: 13 imagens no test.

Conclusão científica do ciclo

O gargalo não é arquitetura — é dado. Com rótulos consistentes e volume adequado, o YOLO11s entrega 0,84–0,95 por classe. Onde o rótulo é incoerente (risco) ou escasso (oxidacao), nenhum aumento de modelo resolve. A auditoria pré-treino já havia descartado ~68% do volume bruto disponível (46k imagens dos datasets weld) por ruído de domínio; este resultado valida quantitativamente a decisão: **curadoria supera volume**.

5. Próximos passos

v1.1 — modelo de produção honesto (imediato)

Re-treinar com as **6 classes saudáveis** (remover risco e oxidacao). Projeção: mAP50 agregado ~0,80 sem nenhuma outra mudança. O modelo passa a prometer apenas o que entrega. As classes removidas retornam na v2 com dados próprios.

v2 — dataset próprio (próximo ciclo)

Ação	Resolve
Fotografar chassi BAJA real (300–500 imgs, iluminação controlada)	domain gap closeup→campo
Rotular internamente com taxonomia própria (sem fusões de classes distintas)	experiência do risco
Coleta dirigida de oxidação/descascamento (active learning nos 15k weld removed)	removidos das raras
Separar bolha de solvent_pop se amostras permitirem	granularidade técnica

6. Artefatos do ciclo

Artefato	Localização
Checkpoint v1 (best.pt, 18,4 MB)	hf://Guguinhaxd/magnus-v2/best.pt
Pipeline de dataset	training/v2/build_dataset.py (dedup workspace-scoped, filtro de negativos envenenados, over
Receita de treino	training/v2/train.py
Avaliação TTA + matriz	training/v2/evaluate.py
Taxonomia e fontes	training/v2/config.py (com datasets excluídos documentados)

Matriz de confusão	runs/detect/magnus_v2/eval/confusion_matrix.png (Colab)
Snapshot anterior	docs/progression/magnus_v0_snapshot.pdf

Bugs corrigidos durante o ciclo (auditoria pré-treino)

1. Dedup entre fontes não colapsava overlap do mesmo autor (risco de leakage train/test). 2. Imagens que perdiam todos os rótulos no remap viravam negativos envenenados. 3. label_smoothing removido do Ultralytics 8.4 quebraria o treino. Todos corrigidos antes da primeira execução — ver commit becb4f7.

Gerado em 2026-06-10 21:08 · Documento auto-suficiente para o projeto de tracking de progressão. Sucede magnus_v0_snapshot.pdf; será sucedido por magnus_v1_1 (6 classes) e magnus_v2 (dataset próprio).